

关系图谱 · 与 PhD 要敲定的细节

逐条过，把结论填进每项的「PhD 结论」。优先级： **先锁** 决定整体走向 · **需确认** loader/数据级 ·

确认默认 已有默认、确认即可。

为什么要先锁 A 组：A 组(范式级)决定蛋白层挂不挂、输入是什么格式——B/C/D 全部建立在它之上。A 没定，下面别动手。当前仓库唯一落地的解析器是 Casanovo(de novo)，默认就走 de novo 主干(到 Peptide 即止)。

速览：最关键的几条

#	问题	不定会怎样
A1	走 de novo 还是数据库搜索	决定蛋白层(Protein/Group/GDS 推断)整层挂不挂
A4	上游分析工具是哪个	决定输入文件格式 → loader 怎么写
B1	Casanovo 实际吐 mzTab 还是 JSON	仓库内已钉 mzTab，但部署工具未证；错了 loader 全废
D2	报告受众 QC / 生物学解读	决定要不要做「解释与注释 Agent」这层
E1	Neo4j 是否装 GDS 插件	不装则蛋白推断(连通分量)跑不了

A. 范式级（最先锁）

A1 走 de novo 还是数据库搜索？ **先锁**

影响： de novo(Casanovo) 只到 **Peptide**、无蛋白归属；数据库搜索(MaxQuant 等)才有 Protein/ProteinGroup 层与 GDS 连通分量推断。这条直接决定整个蛋白层要不要建。

我们的现状： 仓库唯一解析器是 Casanovo(de novo)，默认走主干

Sample→Spectrum→PSM→Peptide，蛋白层代码写好了但不挂。

PhD 结论： _____

A2 实验范式：DDA / DIA? 先锁

影响：DDA 窄窗一谱~一肽；DIA 宽窗一谱混多肽 —— 决定 Spectrum→Peptide 主干边的基数(1:1 还是 1:n)。

我们的现状：当前 join 按「一谱一预测」(Casanovo/DDA 式)实现。

PhD 结论： _____

A3 定量策略：LFQ / TMT / SILAC / 不做定量? 先锁

影响：决定要不要 Quantification 节点、怎么挂(无标/同重标签/同位素)。de novo 通常无定量。

我们的现状：schema 暂无定量层，Casanovo 结果也无强度。

PhD 结论： _____

A4 上游分析工具具体是哪个? 先锁

影响：Casanovo / MaxQuant / FragPipe / DIA-NN —— 直接决定输入文件格式，loader 按格式写。每换一个工具就要新写一个 loader。

我们的现状：只有 Casanovo loader(吃 mzTab)。

PhD 结论： _____

B. Casanovo / 数据格式 (loader 直接依赖)

B1 Casanovo 部署工具实际吐标准 .mztab 还是被包成 JSON? 需确认

影响：loader 完全按格式写；猜错则整条入图链路报错或静默失效。

我们的现状：仓库内已钉死 **mzTab**(解析器 + 测试 + 锚定 Casanovo `ms_io.MztabWriter`)；但部署的外部 MCP 工具是最终权威，代码证不了。请确认它跑出来的是不是标准 **.mztab**。

PhD 结论： _____

B2 Casanovo 工具注册后的真实 `tool_name` 是什么? 需确认

影响: materializer 按 `tool_name` 选 loader。注册表 key 必须等于真实工具名(可能带 `mcp.` 前缀或 `_sequence` 后缀)。

我们的现状: key 暂猜 `casanovo` / `casanovo_sequence`，并加了子串兜底。等工具接上跑一次 `get_run().tool_name` 校准。

PhD 结论: _____

B3 mzTab 的 `index=N` 是否就是输入 mgf 的 0-based 顺序? 需确认

影响: 这是谱图 $\bowtie$ 预测的 **join 钥匙**。两边 index 基准/顺序若不一致 $\rightarrow$ 张冠李戴。

我们的现状: 按「mgf 第 i 张谱 $\leftrightarrow$ mzTab `index=i`」实现(Casanovo 通常如此)。

PhD 结论: _____

B4 一个 run 是否可能有 多个 输入谱图 / 输出结果文件? 需确认

影响: loader 现在按 `data_type` 选第一个匹配文件。若一次 run 多文件，要改成遍历配对。

我们的现状: 按「单谱图 + 单 mztab」处理。

PhD 结论: _____

B5 保留时间 RT 是否需要进图? 需确认

影响: RT 是重要的对齐/校验特征。要的话需扩展 **mgf 解析器**读 `RTINSECONDS` (现在不读, `Spectrum.retention_time=None`)。

PhD 结论: _____

B6 de novo 无 FDR, 要不要按 `score` 阈值过滤低质量预测? 阈值多少? 需确认

影响: 数据库搜索用 `q_value $\leq$ 0.01` 卡 FDR; Casanovo 没有 FDR/decoy, 只有逐肽 `score`。是否设阈值、设多少由 PhD 定。

我们的现状: 全量入图, `q_value=None`、`is_decoy=false`, 不过滤。

PhD 结论: _____

C. 建模决策（已采用默认，确认/可调）

C1 Peptide 身份用 `peptidoform`(带修饰)，裸序列作属性？

确认默认

默认：节点 `key` = `peptidoform` (如 `MEEVEES[+79.966]PEK`)，`stripped_sequence` 作属性。理由：定量/修饰分析在 `peptidoform` 级。

PhD 结论：_____

C2 谱图峰(m/z +强度)不入图、只留文件指针？

确认默认

默认：不入图(几十万谱×上百峰会爆)，`Spectrum.data_object_id` 指回文件，按需回取。

PhD 结论：_____

C3 图库用 Neo4j + GDS，与 SQLite 并存？

确认默认

默认：结果/溯源在 SQLite，图结构+图算法在 Neo4j，靠 `id` 互指；两库无跨库事务，靠 MERGE 幂等。

PhD 结论：_____

C4 `sample_id` / `condition` 怎么定义、从哪来？

需确认

影响：Sample 节点的身份与分组(差异分析按 `condition`)。

我们的现状：`sample_id` 暂从谱图文件名推(`sample:<stem>`)，`condition=""` 空。需要真实的样本元数据来源(样本表 / 命名约定 / 上传时带)。

PhD 结论：_____

D. 图的边界 & 报告

D1 一张图的边界：单实验一张图 / 多实验累积同一张？ 先锁

影响：决定节点 id 的唯一性范围、跨实验比较怎么做、图会长多大。

我们的现状：节点 id 用「文件 oid + index」全局唯一，天然支持累积；但是否真要混多实验由 PhD 定。

PhD 结论： _____

D2 报告受众：QC 技术报告 / 生物学解读？ 先锁

影响：决定要不要做「生物学解释与注释 Agent」(L2 解释层)。纯 QC 只需指标查询；生物学解读才需要挂注释/通路/RAG。

PhD 结论： _____

E. 部署 & 下游增强

E1 Neo4j 实例是否装 GDS 插件？连接信息？ 先锁

影响：蛋白推断(`gds.wcc` 连通分量)依赖 GDS 插件，光装 `neo4j` 驱动跑会报「未知过程」。另需确认 uri / 账号 / 是否社区版(分库受限)。

我们的现状：默认 `bolt://127.0.0.1:7687`，GDS 未确认已装。

PhD 结论： _____

E2 生物学解释要接哪些在线库？ 需确认

影响：决定 MCP_IO 增强通路接哪些：UniProt(蛋白注释) / KEGG(通路) / DeepXiv(文献) / 其它。

PhD 结论： _____

E3 RAG 本地知识库有哪些语料？ 需确认

影响：实验 SOP / 项目文档 / 数据库说明 —— 有没有现成可对接的文档集，决定 RAG 能不能开、喂什么。

PhD 结论： _____

过完这张表后：A 组 + B1/B2 + E1 一锁，loader/materializer 就能从「能跑」推到「对接真实数据跑通」；D2 决定要不要展开下游解释层。建议按 A → B → E → C/D 的顺序谈。

PTAgent 关系图谱 · 与 PhD 确认清单 · 生成于 2026-06-16 · 配套：relational-graph-design.html(设计稿) · materializer-dataflow.md(数据流) · architecture-*.svg(架构图)。