

PTAgent 闭环 · 10 步分镜（每步内部细节）

每一步单独放大其内部小流程，步与步之间不连线。配色：蓝=处理、teal=进图、灰=输入/文件/在线（不进图）。

整合成一张的总览见 [pipeline-steps.svg](#)；项目规格见 [project-spec.md](#)。

注：本文用内联 SVG，VS Code 预览 / 多数本地 Markdown 阅读器可直接渲染；GitHub 会清洗内联 SVG 可能不显示——若需在 GitHub 上看，我可以改成各自独立的 .svg 图片引用。

① 谱图输入 · ingest


文件落盘，库里只登记指针。



三层存储：文件存峰、SQLite 只存指针——峰不进图库。

② Casanovo de novo

逐张谱图推理出肽序列，此刻还没有蛋白。



一张 MS2 → 一条肽 (DDA)；输出只有序列和置信度，还没有蛋白。

③ 压扁 · loaders/casanovo

谱图文件和结果文件按扫描序号 index 配对，拼成一行行扁平记录。



扫描序号 index 是对齐键；spectrum_id = 文件:idx 保唯一；无 PSM 的谱跳过。

④ materialize 主干

扁平化按稳定键 MERGE 去重入图，建实测主干，完事给结果文件盖章。



去重键：peptidoform / spectrum_id / psm_id；先写图后盖章，重跑安全。

⑤ 查库归属 + 蛋白推断

上半是肽查 FASTA 定命中/novel，下半是共享肽的消歧（分组 + unique + razor）。

A. 查库 + novelty



B. 蛋白推断（共享肽消歧·run_inference）



共享肽照实连所有命中蛋白；分不清的报成一组，不删事实，razor 只是主推。

⑥ 注释富集·enrich_annot


按 accession 从 TSV 缓存批量取注释，贴成蛋白节点属性并记版本。



大库不进图、TSV 当缓存；只补 annot_version 空的（幂等），源里没有的留到下次。


⑦ 混合检索 · retrieval

四路信号并行粗筛 → RRF 融合 → 精排 → 写相似边。




⑧ 假说 · hypothesize

顺相似边取邻居母蛋白属性（按 accession 保出处），取共识算置信度。



⑨ deep-search（在线）

拿假说去网上"搜→读→抽→再搜"循环找证据，全程不落库。



⑩ 报告生成

把假说、证据、图谱统计汇总成 Markdown 报告交付，闭环闭合。

